



Far parlare i tuoi contenuti

introduzione pratica alla RAG con WordPress



Luca Baroncini

Info

Project Manager e AI Lead in Net7

Vengo dal mondo WordPress e open source, il passaggio all'AI nel 2023 è stato naturale.

In Net7 mi occupo di chatbot RAG, knowledge base, automazioni e passo una quantità probabilmente eccessiva di tempo con Claude Code.

@baroncini / @LucaBar
<https://github.com/Lukid/>



La search di WordPress fa schifo

Proviamo: "Dove mangio una buona focaccia a Pisa?"

 **WordPress**
Search

Cerca "focaccia" nel testo.

 Con RAG


 *Il Montino - schiacciata + cecina,*

Fonti: "Le migliori schiacce", "Il Montino"

Il RAG capisce il significato, non solo le parole.

Cos'è RAG?

Retrieval-Augmented Generation. Tre parole, un concetto semplice:





Demo Time!

Sito demo: "Le Meraviglie Segrete di Pisa"



WordPress

21 contenuti indicizzati



n8n

13 nodi, 2 workflow



Qdrant

20 vettori ibridi

La qualità parte dai contenuti

Il **Retrieval Augmented Generation (RAG)** non fa miracoli: se i contenuti di base sono poveri o non strutturati correttamente, le risposte generate saranno di conseguenza imprecise o incomplete. Vale il principio "*Garbage in, garbage out*". Per ottenere il massimo dal RAG, è fondamentale curare la qualità e la struttura dei tuoi contenuti.

Strategie di Chunking per il RAG

1	2	3
Fixed-size (ogni N token) Qualità: ❌ Scarsa Ideale per: Solo prototipi o dati non strutturati.	Header/section-based Qualità: ✅ Buona Ideale per: Markdown, testo piatto con struttura chiara.	Structure-aware (CMS) Qualità: 🏆 Ottima Ideale per: Contenuti CMS strutturati come WordPress.



L'architettura dei contenuti la struttura semantica. WordPress vi dà già la struttura — post, pagine, categorie, metadati/campi.

Cos'è un embedding?

Un embedding trasforma le parole in **coordinate nello spazio**. Significati simili = punti vicini.



Cluster CIBO

"schiacciata pisana" e "focaccia" →
vicinissime



Cluster LUOGHI

"Torre Pendente" e "Piazza dei
Miracoli" → **vicinissime**



Fuori da tutto

"debugging PHP" → **lontanissimo
da tutti** 😂

Ecco perché "focaccia" trova "schiacciata" — sono vicine nello **spazio dei significati**, anche se le parole sono diverse.



[animazione interattiva con i punti che si raggruppano in cluster]

Il Vector Database

Dove vivono gli embedding: Qdrant

Open source, gratis, velocissimo.

- Salva i vettori dei tuoi contenuti
- Scala su milioni di documenti
- Trova i più simili in millisecondi

Pensalo come **Google Maps dei significati**: i contenuti sono punti sulla mappa, la domanda è "trovami i più vicini".



Sito Demo

"Le Meraviglie Segrete di Pisa"

- 20 contenuti indicizzati
- 1 punto per post/pagina

2 vettori per punto: **Dense + BM25**

Hybrid Search: fulltext + semantica

Due motori diversi, un risultato migliore. Né BM25 né Dense da soli bastano — insieme si completano.



💡 **BM25 è insostituibile** per nomi di locali, attività, persone, codici prodotto, SKU, username — dove il testo esatto conta. Dense capisce il significato. Hybrid li combina entrambi: nessun caso rimane scoperto.

Quando ha senso usare RAG?

✓ Sì, provaci

- Hai molti contenuti (>20 pagine)
- Gli utenti fanno domande specifiche
- La search interna non basta
- Vuoi risposte in linguaggio naturale
- I contenuti si aggiornano regolarmente

✗ Forse no

- Hai 5 pagine statiche
- Non hai budget per API LLM
- Servono risposte certificate/legali
- Non puoi investire in manutenzione



"Ma con context window da 1M token, serve ancora RAG?" Sì. Costo 100x, latenza alta, l'LLM si perde nel testo lungo. RAG si aggiorna incrementalmente. E non tutto deve diventare un chatbot — a volte basta una buona search.

WordCamp
torino 2026

Grazie!

A voi le domande

